

Mục lục

Danh mục các từ viết tắt, khái niệm và thuật ngữ	4
1 Giới thiệu	6
1.1 Bối cảnh và động lực nghiên cứu	6
1.2 Vấn đề đặt ra: khoảng cách ngữ nghĩa giữa tín hiệu cộng tác và LLM	7
1.3 Khoảng trống nghiên cứu	8
1.4 Mục tiêu và đóng góp	9
1.5 Bố cục luận văn	10
2 Các công trình liên quan	12
2.1 Lọc cộng tác truyền thống	12
2.1.1 Phân rã ma trận	13
2.1.2 Lọc cộng tác dựa trên đồ thị	13
2.1.3 Hạn chế của lọc cộng tác thuần túy	13
2.2 Mô hình ngôn ngữ lớn cho hệ thống tư vấn	14
2.2.1 Hai hướng khai thác LLM	14
2.2.2 Giới hạn độ dài ngữ cảnh	15
2.3 Tích hợp biểu diễn cộng tác vào LLM	15
2.3.1 Ánh xạ MLP: CoLLM	16
2.3.2 Căn chỉnh tương phản: SellaRec	16
2.3.3 Mã hóa văn bản: BinLLM	17
2.3.4 Thách nghiệm tham số LLM: CoRA	17

2.3.5	Căn chỉnh qua Q-Former: ILM	18
2.3.6	So sánh các phương pháp	18
2.4	Cơ sở kiến trúc Q-Former	19
2.5	Khoảng trống nghiên cứu và định hướng đề xuất	20
3	Phương pháp đề xuất	22
3.1	Kiến trúc tổng thể	22
3.2	Mô-đun phân rã ma trận	23
3.3	Cầu nối Q-Former	25
3.3.1	Động cơ lựa chọn Q-Former	25
3.3.2	Q-Former cho bài toán gợi ý	26
3.3.3	Tích hợp biểu diễn cộng tác qua soft token	27
3.3.4	Điều kiện hóa truy vấn theo người dùng	28
3.3.5	Hàm mất mát bảo toàn thứ hạng theo người dùng	29
3.4	Biểu diễn cộng tác đa token	30
3.5	Huấn luyện ba giai đoạn	31
3.5.1	Tiền huấn luyện biểu diễn	31
3.5.2	Tiền huấn luyện sinh	32
3.5.3	Tinh chỉnh CTR	33
3.6	Tổng kết chương	33
4	Thực nghiệm và kết quả	35
4.1	Thiết lập thực nghiệm	35
4.1.1	Tập dữ liệu	35
4.1.2	Phân chia dữ liệu và thiết lập đánh giá	36
4.1.3	Mô hình so sánh	36
4.1.4	Chỉ số đánh giá	37
4.1.5	Chi tiết cài đặt	37
4.2	Kết quả tổng thể	39
4.3	Phân tích khác biệt AUC–uAUC	41
4.4	Thí nghiệm loại bỏ thành phần	41
4.5	Phân tích bổ sung	43

4.5.1	Khoảng cách ngữ nghĩa	43
4.5.2	Phân tích theo nhóm warm/cold	43
4.6	Thảo luận	44
4.6.1	Đối chiếu với ILM	44
4.6.2	Ưu điểm và hạn chế của Q-Former	44
4.7	Hạn chế nghiên cứu	45
5	Kết luận và hướng nghiên cứu	46
5.1	Tóm tắt đóng góp	46
5.2	Kết quả chính	47
5.3	Hạn chế nghiên cứu	48
5.4	Hướng nghiên cứu tương lai	48
	Tài liệu tham khảo	50

Danh mục các từ viết tắt, khái niệm và thuật ngữ

Từ viết tắt	Từ đầy đủ	Tiếng Việt
LLM	Large Language Model	Mô hình ngôn ngữ lớn
CF	Collaborative Filtering	Lọc cộng tác
MF	Matrix Factorization	Phân rã ma trận
Embed- ding	Embedding vector	Véc-tơ biểu diễn đặc trưng (giữ nguyên thuật ngữ “embedding”)
MLP	Multi-Layer Perceptron	Perceptron nhiều lớp
NCF	Neural Collaborative Filtering	Lọc cộng tác dùng mạng nơ-ron
GCN	Graph Convolutional Network	Mạng tích chập đồ thị
DIN	Deep Interest Network	Mạng học sở thích sâu
Q-Former	Querying Transformer	Bộ biến đổi truy vấn (giữ tên Q-Former)

Từ viết tắt	Từ đầy đủ	Tiếng Việt
BLIP-2	Bootstrapping Language-Image Pre-training	Tiền huấn luyện ảnh-ngôn ngữ (BLIP-2)
LoRA	Low-Rank Adaptation	Thích nghi hạng thấp
BPR	Bayesian Personalized Ranking	Xếp hạng cá nhân hóa theo Bayes
BCE	Binary Cross-Entropy	Entropy chéo nhị phân
InfoNCE	Info Noise-Contrastive Estimation	Ước lượng tương phản dựa trên nhiễu
CIE	Collaborative Information Encoding	Mã hóa thông tin cộng tác
CTR	Click-Through Rate	Tỉ lệ nhấp
AUC	Area Under the ROC Curve	Diện tích dưới đường cong ROC
uAUC	User-level AUC	AUC trung bình theo từng người dùng
ROC	Receiver Operating Characteristic	Đường cong đặc trưng hoạt động của bộ phân loại
NDCG	Normalized Discounted Cumulative Gain	Độ lợi tích lũy chiết khấu chuẩn hóa

Chương 1

Giới thiệu

1.1 Bối cảnh và động lực nghiên cứu

Trong thập kỷ qua, hệ thống tư vấn (recommender system) đã trở thành một thành phần quan trọng của nhiều nền tảng số, đặc biệt trong thương mại điện tử, dịch vụ phát trực tuyến và mạng xã hội. Nhiệm vụ cốt lõi của hệ thống tư vấn là ước lượng mức độ phù hợp giữa người dùng và sản phẩm từ dữ liệu tương tác lịch sử, qua đó cung cấp các đề xuất được cá nhân hóa [1].

Lọc cộng tác (collaborative filtering – CF) là một trong những nền tảng quan trọng của các hệ thống tư vấn hiện đại. Trong đó, phân rã ma trận (matrix factorization – MF) [2] biểu diễn người dùng và sản phẩm bằng các véc-tơ ẩn trong một không gian đặc trưng thấp chiều, sao cho mức độ tương thích giữa hai biểu diễn phản ánh xu hướng ưa thích của người dùng. Các phương pháp mở rộng như LightGCN [3] tiếp tục khai thác cấu trúc đồ thị của dữ liệu tương tác và đã cho thấy hiệu quả trên nhiều bộ dữ liệu chuẩn. Tuy nhiên, các phương pháp dựa chủ yếu vào tín hiệu cộng tác vẫn đối mặt với ba hạn chế chính. Thứ nhất, dữ liệu tương tác thường rất thưa, khiến biểu diễn của các người dùng hoặc sản phẩm có ít tương tác kém ổn định. Thứ hai, bài toán khởi động nguội (cold-start) gây khó khăn cho việc xây dựng biểu diễn có chất lượng đối với người dùng hoặc

sản phẩm mới. Thứ ba, các biểu diễn cộng tác không trực tiếp khai thác thông tin ngữ nghĩa từ nội dung văn bản mô tả sản phẩm hoặc sở thích người dùng.

Sự phát triển nhanh chóng của các mô hình ngôn ngữ lớn (large language model – LLM) mở ra một hướng tiếp cận bổ sung cho các hạn chế trên. Nhờ được tiền huấn luyện trên quy mô dữ liệu văn bản lớn, LLM sở hữu khả năng biểu diễn ngữ nghĩa và suy luận phong phú. Việc kết hợp LLM với hệ thống tư vấn hiện được nghiên cứu theo hai hướng chính [4]. Hướng thứ nhất, LLM-enhanced, sử dụng LLM như một bộ mã hóa để làm giàu biểu diễn người dùng và sản phẩm, sau đó đưa các biểu diễn này vào mô hình gợi ý truyền thống. Hướng thứ hai, LLMs-as-RS, biểu diễn trực tiếp bài toán gợi ý dưới dạng một tác vụ ngôn ngữ, trong đó LLM vừa xử lý ngữ cảnh vừa sinh đầu ra gợi ý. Hướng LLMs-as-RS đặc biệt đáng chú ý vì có khả năng tận dụng tri thức ngữ nghĩa có sẵn của LLM trong các tình huống cold-start và hỗ trợ diễn giải kết quả bằng ngôn ngữ tự nhiên.

Luận văn này tập trung vào hướng LLMs-as-RS, với mục tiêu khai thác đồng thời thông tin ngữ nghĩa từ LLM và tín hiệu cộng tác từ lịch sử tương tác người dùng–sản phẩm.

1.2 Vấn đề đặt ra: khoảng cách ngữ nghĩa giữa tín hiệu cộng tác và LLM

Khi bài toán gợi ý được biểu diễn như một tác vụ ngôn ngữ, một câu hỏi quan trọng là làm thế nào để đưa lịch sử hành vi của người dùng vào LLM một cách hiệu quả. Cách trực tiếp nhất là chuyển lịch sử tương tác sang văn bản, chẳng hạn liệt kê các sản phẩm hoặc bộ phim mà người dùng đã tương tác, rồi bổ sung phần này vào chỉ dẫn đầu vào. Tuy nhiên, đối với người dùng có lịch sử dài, cách biểu diễn này nhanh chóng làm tăng số lượng token và có thể vượt quá giới hạn ngữ cảnh của LLM, đồng thời làm tăng đáng kể chi phí tính toán [5].

Một hướng thay thế là nén thông tin hành vi thành biểu diễn véc-tơ. Thay vì đưa toàn bộ lịch sử dưới dạng văn bản, mô hình cộng tác tổng hợp lịch sử tương tác thành một véc-tơ dày đặc, sau đó chuyển véc-tơ này sang không gian embedding của LLM và đưa vào như một soft token. Cách tiếp cận này cho phép truyền tín hiệu cộng tác vào LLM mà không làm tăng đáng kể độ dài ngữ cảnh.

CoLLM [5] là một công trình tiêu biểu theo hướng này. Mô hình sử dụng một MLP để ánh xạ biểu diễn cộng tác từ không gian của mô hình truyền thống sang không gian embedding của LLM, sau đó chèn kết quả vào prompt dưới dạng soft token. Cơ chế này đơn giản và hiệu quả, nhưng phép ánh xạ được áp dụng độc lập trên từng véc-tơ cộng tác. Mỗi biểu diễn đầu vào được chuyển thành một soft token thông qua cùng một hàm ánh xạ, nên mô-đun này không trực tiếp mô hình hóa quan hệ giữa nhiều nguồn tín hiệu cộng tác trước khi chúng được đưa vào LLM, cũng như không có cơ chế chọn lọc thích nghi theo ngữ cảnh.

Thách thức cốt lõi nằm ở sự khác biệt giữa hai không gian biểu diễn. Biểu diễn cộng tác được học từ cấu trúc tương tác người dùng–sản phẩm, trong khi không gian của LLM được hình thành chủ yếu từ dữ liệu ngôn ngữ. Do nguồn gốc huấn luyện khác nhau, việc chuyển đổi giữa hai không gian không chỉ là bài toán thay đổi số chiều, mà còn là bài toán căn chỉnh biểu diễn. Từ đó, luận văn đặt ra câu hỏi: liệu một mô-đun căn chỉnh có khả năng chọn lọc và tổng hợp tín hiệu cộng tác theo từng mẫu có thể cải thiện quá trình tích hợp tín hiệu cộng tác vào LLM so với phép ánh xạ pointwise bằng MLP hay không?

1.3 Khoảng trống nghiên cứu

Q-Former, được giới thiệu trong BLIP-2 [6], là một kiến trúc trung gian được thiết kế để kết nối đặc trưng ảnh với mô hình ngôn ngữ. Thành phần này sử dụng một tập truy vấn học được (learned query tokens) kết hợp với cross-attention để khai thác có chọn lọc thông tin từ đặc trưng đầu vào.

Thay vì chuyển toàn bộ đầu vào thông qua một phép chiếu trực tiếp, các truy vấn học cách thu nhận và tổng hợp những phần thông tin phù hợp cho nhiệm vụ phía sau.

Về nguyên tắc, cơ chế này cũng phù hợp với bài toán tích hợp biểu diễn cộng tác vào LLM. Biểu diễn cộng tác có thể thay thế đặc trưng ảnh ở phía đầu vào, trong khi các truy vấn của Q-Former đóng vai trò tổng hợp và biến đổi tín hiệu trước khi chuyển sang không gian của LLM. ILM [7] đã khai thác ý tưởng này trong bài toán gợi ý, cho thấy Q-Former có thể được sử dụng như một mô-đun trung gian giữa thông tin cộng tác và mô hình ngôn ngữ.

Tuy nhiên, vẫn còn hai khoảng trống liên quan trực tiếp đến mục tiêu của luận văn. Thứ nhất, ILM không được đánh giá theo bài toán dự đoán CTR với AUC và uAUC như CoLLM và các công trình cùng hướng, nên chưa tạo ra cơ sở so sánh trực tiếp giữa cơ chế Q-Former và phép ánh xạ MLP trong cùng thiết lập đánh giá. Thứ hai, mô-đun Q-Former trong ILM chưa được khảo sát cùng các kỹ thuật huấn luyện nhằm cải thiện tới chất lượng phân biệt giữa người dùng và chất lượng xếp hạng trong từng người dùng (AUC/uAUC), cũng như lựa chọn biểu diễn nhiều soft token.

Từ các khoảng trống trên, luận văn xây dựng CoQLLM, trong đó Q-Former được sử dụng làm mô-đun căn chỉnh giữa biểu diễn cộng tác và LLM. Mô hình được đánh giá trên bài toán dự đoán CTR với AUC và uAUC, đồng thời được bổ sung các cơ chế điều kiện hóa truy vấn theo người dùng, mục tiêu bảo toàn thứ hạng trong từng người dùng và biểu diễn cộng tác đa token.

1.4 Mục tiêu và đóng góp

Luận văn hướng đến hai mục tiêu chính.

Mục tiêu 1 – Xây dựng mô-đun căn chỉnh Q-Former cho tín hiệu cộng tác. Luận văn thiết kế và hiện thực CoQLLM với ba thành phần chính: mô hình MF đóng băng, Q-Former làm mô-đun căn chỉnh,

và LLM Vicuna-7B-v1.5 [8] kết hợp LoRA [9]. Tín hiệu cộng tác được xử lý bởi Q-Former trước khi được đưa vào LLM dưới dạng soft token. Trên kiến trúc cơ sở này, luận văn khảo sát điều kiện hóa truy vấn theo người dùng, mục tiêu bảo toàn thứ hạng trong từng người dùng và biểu diễn đa token.

Mục tiêu 2 – Đánh giá Q-Former cho bài toán CTR. Luận văn đánh giá CoQLLM trên MovieLens-1M và Amazon-Book bằng AUC và uAUC, đồng thời đối chiếu với các baseline như CoLLM, BinLLM và CoRA trong phạm vi số liệu tương thích.

Từ hai mục tiêu trên, các đóng góp chính của luận văn gồm:

1. **Thích nghi Q-Former cho bài toán gợi ý dựa trên tín hiệu cộng tác.** Đặc trưng cộng tác từ MF được sử dụng thay cho đặc trưng ảnh trong cơ chế cross-attention của Q-Former và được chuyển thành soft token đầu vào cho LLM. Trên nền tảng này, luận văn bổ sung điều kiện hóa truy vấn theo người dùng, mục tiêu bảo toàn thứ hạng trong từng người dùng và khảo sát biểu diễn đa token.
2. **Đánh giá có hệ thống theo AUC và uAUC.** CoQLLM được đánh giá trên MovieLens-1M và Amazon-Book theo thiết lập dự đoán nhị phân, cho phép đối chiếu trực tiếp hơn với dòng phương pháp CoLLM. Bên cạnh kết quả tổng thể, luận văn thực hiện phân tích thành phần và phân tích warm/cold để làm rõ vai trò của từng cơ chế và giới hạn của biểu diễn cộng tác.

1.5 Bố cục luận văn

Phần còn lại của luận văn được tổ chức như sau. Chương 2 trình bày các công trình liên quan, gồm lọc cộng tác truyền thống, các hướng khai thác LLM cho hệ thống tư vấn, các phương pháp tích hợp biểu diễn cộng tác vào LLM và cơ sở kiến trúc Q-Former. Chương 3 mô tả phương pháp đề xuất CoQLLM, bao gồm kiến trúc tổng thể, mô-đun MF, Q-Former, cơ

chế soft token, các kỹ thuật huấn luyện bổ sung và quy trình huấn luyện ba giai đoạn. Chương 4 trình bày thiết lập thực nghiệm, kết quả so sánh, phân tích thành phần, phân tích warm/cold và thảo luận. Chương 5 tổng kết các đóng góp, nêu các hạn chế và đề xuất hướng nghiên cứu tiếp theo.

Chương 2

Các công trình liên quan

Chương này trình bày cơ sở lý thuyết và các công trình liên quan theo bốn nhóm. Mục 2.1 giới thiệu các phương pháp lọc cộng tác và những hạn chế chính của chúng. Mục 2.2 trình bày hai hướng khai thác LLM trong hệ thống tư vấn và vấn đề độ dài ngữ cảnh. Mục 2.3 tổng hợp các cơ chế tích hợp biểu diễn cộng tác vào LLM, từ ánh xạ MLP, học tương phản và mã hóa văn bản đến thích nghi tham số và Q-Former. Cuối cùng, Mục 2.4 trình bày cơ sở kiến trúc Q-Former, làm nền tảng cho phương pháp được đề xuất ở Chương 3.

2.1 Lọc cộng tác truyền thống

Lọc cộng tác (collaborative filtering – CF) khai thác các mẫu tương tác giữa người dùng và sản phẩm để ước lượng sở thích. Trực giác cơ bản là những người dùng có hành vi tương tự trong quá khứ có xu hướng quan tâm đến các sản phẩm tương tự trong tương lai. Nhóm phương pháp này chủ yếu dựa trên ma trận tương tác người dùng–sản phẩm và không yêu cầu thông tin nội dung của sản phẩm [1].

2.1.1 Phân rã ma trận

Phân rã ma trận (matrix factorization – MF) [2] là một phương pháp nền tảng của lọc cộng tác. MF ánh xạ mỗi người dùng u và sản phẩm i thành các véc-tơ ẩn $e_u, e_i \in \mathbb{R}^d$, sao cho tích vô hướng $e_u^\top e_i$ phản ánh mức độ tương thích giữa người dùng và sản phẩm. Tùy dạng dữ liệu, mô hình có thể được tối ưu bằng hồi quy trên các đánh giá quan sát được hoặc bằng các mục tiêu xếp hạng cặp như BPR [10].

Ưu điểm của MF là cấu trúc đơn giản, khả năng mở rộng tốt và hiệu quả đã được kiểm chứng trên nhiều bộ dữ liệu. Tuy nhiên, phép tương tác dựa trên tích vô hướng giới hạn khả năng mô hình hóa các quan hệ phi tuyến phức tạp. Neural Collaborative Filtering (NCF) [11] mở rộng ý tưởng này bằng cách sử dụng mạng nơ-ron nhiều lớp để mô hình hóa tương tác người dùng–sản phẩm linh hoạt hơn.

2.1.2 Lọc cộng tác dựa trên đồ thị

Dữ liệu tương tác người dùng–sản phẩm có thể được biểu diễn dưới dạng đồ thị hai phía. LightGCN [3] khai thác cấu trúc này bằng cách lan truyền và tổng hợp tuyến tính embedding giữa các nút lân cận qua nhiều lớp. Nhờ tận dụng quan hệ bậc cao trong đồ thị tương tác, LightGCN đạt hiệu quả cao trên nhiều bộ dữ liệu gợi ý và trở thành một baseline phổ biến cho các phương pháp dựa trên tín hiệu cộng tác.

2.1.3 Hạn chế của lọc cộng tác thuần túy

Mặc dù có hiệu quả tốt trong các kịch bản giàu tương tác, lọc cộng tác truyền thống vẫn có ba hạn chế đáng chú ý. **Thứ nhất, dữ liệu thưa:** phần lớn cặp người dùng–sản phẩm không có tương tác quan sát được, khiến embedding của các thực thể ít tương tác kém tin cậy. **Thứ hai, cold-start:** người dùng hoặc sản phẩm mới gần như không có tín hiệu cộng tác để xây dựng biểu diễn. **Thứ ba, thiếu thông tin ngữ nghĩa:**

embedding cộng tác chủ yếu phản ánh cấu trúc đồng xuất hiện trong dữ liệu tương tác và không trực tiếp biểu diễn nội dung văn bản của sản phẩm hay mô tả sở thích người dùng.

Các hạn chế này là một trong những động lực thúc đẩy việc kết hợp mô hình ngôn ngữ với hệ thống tư vấn.

2.2 Mô hình ngôn ngữ lớn cho hệ thống tư vấn

Nhờ được tiền huấn luyện trên tập dữ liệu văn bản quy mô lớn, LLM có khả năng biểu diễn ngữ nghĩa và suy luận vượt trội so với các mô hình chỉ khai thác tín hiệu tương tác. Do đó, việc tích hợp LLM vào hệ thống tư vấn đã trở thành một hướng nghiên cứu đáng chú ý trong những năm gần đây [4].

2.2.1 Hai hướng khai thác LLM

Các phương pháp kết hợp LLM với hệ thống tư vấn có thể được chia thành hai nhóm chính.

LLM-enhanced. LLM được sử dụng như một bộ mã hóa để tạo biểu diễn ngữ nghĩa cho người dùng, sản phẩm hoặc nội dung liên quan. Các biểu diễn này sau đó được đưa vào mô hình gợi ý hoặc mô hình xếp hạng truyền thống. Trong thiết kế này, LLM chủ yếu đóng vai trò trích xuất đặc trưng, còn quyết định gợi ý cuối cùng vẫn do mô hình phía sau thực hiện.

LLMs-as-RS. Bài toán gợi ý được biểu diễn trực tiếp dưới dạng tác vụ ngôn ngữ. P5 [12] là một công trình tiêu biểu, thống nhất nhiều nhiệm vụ gợi ý thành các cặp câu hỏi–trả lời và huấn luyện một mô hình ngôn ngữ để xử lý chúng. BIGRec [13] tinh chỉnh LLM để sinh ra mô tả của một sản phẩm phù hợp với sở thích người dùng, sau đó đối sánh biểu diễn

của đầu ra sinh với biểu diễn của các sản phẩm thực tế trong hệ thống để xác định sản phẩm được gợi ý.

Hướng LLMs-as-RS có lợi thế trong việc tận dụng tri thức ngữ nghĩa và hỗ trợ các trường hợp cold-start thông qua mô tả văn bản. Luận văn này tiếp tục theo hướng đó nhưng tập trung vào cách đưa tín hiệu cộng tác vào LLM một cách hiệu quả.

2.2.2 Giới hạn độ dài ngữ cảnh

Một cách tự nhiên để cung cấp thông tin hành vi cho LLM là chuyển lịch sử tương tác thành văn bản và đưa trực tiếp vào prompt. Tuy nhiên, lịch sử của một người dùng thực tế có thể gồm hàng trăm hoặc hàng nghìn tương tác. Khi mỗi sản phẩm chiếm nhiều token, toàn bộ lịch sử có thể nhanh chóng vượt quá giới hạn ngữ cảnh hoặc làm chi phí suy luận tăng đáng kể.

CoLLM [5] chỉ ra rằng việc biểu diễn toàn bộ lịch sử dưới dạng văn bản không phải lúc nào cũng khả thi. Một giải pháp là sử dụng biểu diễn cộng tác nén, được học từ lịch sử tương tác, rồi chuyển biểu diễn này thành soft token để đưa vào LLM. Cách tiếp cận đó dẫn tới bài toán trung tâm của luận văn: căn chỉnh biểu diễn cộng tác với không gian embedding của LLM như thế nào để thông tin được khai thác hiệu quả.

2.3 Tích hợp biểu diễn cộng tác vào LLM

Các công trình gần đây đề xuất nhiều cơ chế khác nhau để kết hợp tín hiệu cộng tác với LLM. Phần này tập trung vào năm hướng có liên quan trực tiếp đến luận văn và phân tích vai trò, ưu điểm cũng như hạn chế của từng cơ chế.

2.3.1 Ánh xạ MLP: CoLLM

CoLLM [5] là baseline quan trọng của luận văn. Mô hình sử dụng một MLP hai lớp theo cấu trúc Linear–ReLU–Linear, với tầng ẩn có kích thước gấp mười lần chiều embedding cộng tác, để ánh xạ biểu diễn cộng tác sang không gian embedding của LLM. Mỗi véc-tơ cộng tác được chuyển thành một soft token và chèn vào prompt. LLM sau đó thực hiện dự đoán nhị phân dưới dạng xác suất cho câu trả lời “Yes” hoặc “No”.

Quy trình huấn luyện của CoLLM gồm hai bước chính. Ở bước đầu, LoRA được tinh chỉnh trên phần prompt chỉ chứa thông tin văn bản để LLM thích nghi với nhiệm vụ gợi ý mà chưa sử dụng tín hiệu cộng tác. Ở bước sau, mô-đun CIE được huấn luyện để ánh xạ biểu diễn cộng tác của người dùng và sản phẩm vào không gian embedding của LLM, trong khi các thành phần đã học ở bước trước được giữ cố định theo cấu hình mặc định.

Ưu điểm của CoLLM nằm ở cấu trúc đơn giản và chi phí bổ sung tương đối nhỏ. Tuy nhiên, phép ánh xạ MLP được áp dụng độc lập trên từng embedding. Cùng một hàm ánh xạ được sử dụng cho mọi mẫu và không trực tiếp tổng hợp quan hệ giữa nhiều nguồn tín hiệu cộng tác trước khi chúng đi vào LLM. Đồng thời, mỗi véc-tơ cộng tác được cô đọng thành một soft token duy nhất, nên mô-đun không có cơ chế riêng để phân bổ hoặc chọn lọc các thành phần thông tin theo mức độ liên quan với ngữ cảnh hiện tại.

2.3.2 Căn chỉnh tương phản: SellaRec

SellaRec [14] căn chỉnh không gian cộng tác và không gian ngôn ngữ bằng học tương phản (contrastive learning), sử dụng mục tiêu InfoNCE để kéo gần biểu diễn tương ứng của cùng một sản phẩm và đẩy xa các biểu diễn không tương ứng. Cơ chế này cung cấp một mục tiêu huấn luyện trực tiếp cho việc thu hẹp khoảng cách giữa hai không gian biểu diễn.

SellaRec đã được đánh giá trên bài toán CTR với AUC và uAUC trên MovieLens-1M, do đó cung cấp bằng chứng thực nghiệm cho hướng căn chỉnh dựa trên học tương phản. Trong khi đó, Q-Former đại diện cho một cơ chế khác: thay vì căn chỉnh chủ yếu thông qua một mục tiêu tương phản ở mức biểu diễn, Q-Former sử dụng các truy vấn học được để chọn lọc và tổng hợp tín hiệu cộng tác trước khi chuyển sang không gian của LLM. Vì vậy, SellaRec và CoQLLM có thể được xem là hai hướng tiếp cận bổ sung về cơ chế hơn là các biến thể trực tiếp của nhau.

Cần lưu ý rằng SellaRec sử dụng Qwen2-7B-Base [15], trong khi luận văn sử dụng Vicuna-7B-v1.5 [8]. Sự khác biệt về backbone và thiết lập dữ liệu hạn chế khả năng diễn giải chênh lệch số liệu như một so sánh thuần túy giữa hai cơ chế căn chỉnh.

2.3.3 Mã hóa văn bản: BinLLM

BinLLM [16] chuyển biểu diễn cộng tác thành chuỗi ký tự nhị phân, sau đó đưa chuỗi này vào LLM như văn bản thông thường. Thiết kế này có ưu điểm là đơn giản về giao diện với LLM và không yêu cầu cơ chế soft token chuyên biệt.

Hạn chế của phương pháp nằm ở bước rời rạc hóa. Việc chuyển một véc-tơ liên tục thành chuỗi nhị phân có thể làm mất một phần thông tin của biểu diễn ban đầu. Bên cạnh đó, chuỗi nhị phân không có ngữ nghĩa tự nhiên trong từ vựng của LLM, khiến mô hình phải học thêm cách diễn giải cấu trúc mã hóa này trước khi có thể khai thác nó cho nhiệm vụ gợi ý.

2.3.4 Thích nghi tham số LLM: CoRA

CoRA [17] đưa tín hiệu cộng tác vào LLM theo một hướng khác. Thay vì chèn tín hiệu vào không gian đầu vào dưới dạng soft token, CoRA biến đổi biểu diễn cộng tác thành các cặp nhật trọng số hạng thấp phụ thuộc từng mẫu và bổ sung chúng vào các lớp attention của LLM. Nhờ đó, tính

toán bên trong LLM có thể được điều chỉnh theo từng cặp người dùng–sản phẩm.

Cơ chế này đại diện cho một hướng thiết kế khác với CoQLLM. CoRA tác động trực tiếp lên tham số hiệu dụng của LLM trong quá trình suy luận, trong khi CoQLLM giữ đường tích hợp ở không gian đầu vào thông qua soft token. Luận văn không hiện thực lại cơ chế sinh trọng số của CoRA mà sử dụng kết quả của mô hình như một baseline bổ sung trên Amazon-Book để định vị CoQLLM so với một hướng tích hợp khác.

2.3.5 Căn chỉnh qua Q-Former: ILM

ILM [7] là một công trình sử dụng Q-Former để kết nối thông tin cộng tác với mô hình ngôn ngữ trong bài toán gợi ý. Q-Former sử dụng tập truy vấn học được kết hợp với cross-attention để khai thác thông tin từ các biểu diễn cộng tác, thay vì áp dụng một phép chiếu độc lập trên từng véc-tơ.

Cơ chế này phù hợp với mục tiêu căn chỉnh của luận văn vì cho phép mô hình học cách tổng hợp tín hiệu cộng tác trước khi đưa vào LLM. Tuy nhiên, ILM không báo cáo kết quả theo thiết lập CTR với AUC và uAUC như CoLLM, nên chưa cung cấp cơ sở để so sánh trực tiếp hiệu quả của Q-Former với MLP trong cùng giao thức đánh giá.

2.3.6 So sánh các phương pháp

Bảng 2.1 tổng hợp các cơ chế tích hợp tín hiệu cộng tác được thảo luận ở trên.

Tổng hợp các công trình cho thấy Q-Former là một hướng đáng khảo sát cho bài toán căn chỉnh biểu diễn cộng tác với LLM nhờ khả năng tổng hợp tín hiệu thông qua các truy vấn học được. Tuy nhiên, hướng này vẫn thiếu đánh giá trực tiếp trong thiết lập CTR với AUC/uAUC và chưa được khảo sát đầy đủ cùng các cơ chế huấn luyện hướng tới đặc tính của hai độ đo này. Đây là khoảng trống mà luận văn tập trung giải quyết.

2.4 Cơ sở kiến trúc Q-Former

BLIP-2 [6] giới thiệu Q-Former (Querying Transformer) như một mô-đun trung gian giữa bộ mã hóa ảnh đóng băng và mô hình ngôn ngữ đóng băng. Mục tiêu của Q-Former là trích xuất một tập biểu diễn nhỏ gọn từ đặc trưng đầu vào liên tục, sau đó chuyển các biểu diễn này sang dạng mà LLM có thể khai thác mà không cần cập nhật toàn bộ hai mô hình lớn.

Q-Former sử dụng một tập truy vấn học được $\mathbf{Q} \in \mathbb{R}^{N_q \times d}$, thường gồm một số lượng hữu hạn query token, kết hợp với các lớp Transformer. Trong quá trình xử lý, hai cơ chế attention đóng vai trò chính:

1. *Self-attention* giữa các truy vấn, cho phép các query token trao đổi thông tin và phối hợp trong việc phân chia vai trò biểu diễn.
2. *Cross-attention* từ truy vấn đến đặc trưng đầu vào, cho phép mỗi truy vấn tổng hợp thông tin từ nguồn đầu vào với trọng số phụ thuộc vào nội dung của mẫu.

Đầu ra của Q-Former là một tập véc-tơ truy vấn đã được cập nhật, ký hiệu $\mathbf{Z} \in \mathbb{R}^{N_q \times d}$. Trong BLIP-2, các véc-tơ này được chiếu sang không gian embedding của LLM và ghép với prompt văn bản.

BLIP-2 huấn luyện Q-Former theo hai giai đoạn. Giai đoạn đầu tập trung học biểu diễn qua các mục tiêu tương phản ảnh–văn bản (ITC), so khớp ảnh–văn bản (ITM) và sinh văn bản có điều kiện (ITG). Giai đoạn sau căn chỉnh đầu ra của Q-Former với mô hình ngôn ngữ để các biểu diễn trung gian có thể được LLM khai thác trong quá trình sinh.

Đối với bài toán của luận văn, đặc trưng ảnh được thay thế bằng biểu diễn cộng tác. Khi đó, Q-Former được sử dụng như một mô-đun căn chỉnh: các truy vấn học được tổng hợp thông tin từ embedding người dùng, sản phẩm mục tiêu và lịch sử trước khi đầu ra được chuyển sang không gian embedding của LLM.

2.5 Khoảng trống nghiên cứu và định hướng đề xuất

Từ các nhóm công trình đã phân tích, có thể rút ra hai nhận xét. Thứ nhất, việc đưa tín hiệu cộng tác vào LLM dưới dạng biểu diễn nén là cần thiết khi lịch sử tương tác quá dài để biểu diễn đầy đủ bằng văn bản. Thứ hai, các cơ chế tích hợp hiện có khác nhau đáng kể về cách căn chỉnh giữa không gian cộng tác và không gian ngôn ngữ.

CoLLM cung cấp một baseline đơn giản dựa trên MLP pointwise, trong khi Q-Former cung cấp khả năng tổng hợp nhiều nguồn tín hiệu thông qua truy vấn học được và attention. ILM cho thấy hướng Q-Former có thể áp dụng trong gợi ý, nhưng chưa đánh giá theo AUC/uAUC trong thiết lập CTR tương tự CoLLM. Do đó, luận văn tập trung vào việc xây dựng và đánh giá một mô-đun căn chỉnh Q-Former trong cùng nhóm bài toán, đồng thời khảo sát các cơ chế huấn luyện hướng tới AUC và uAUC.

Bảng 2.1: So sánh các phương pháp tích hợp biểu diễn cộng tác vào LLM

Phương pháp	Cơ chế tích hợp	Điểm mạnh	Hạn chế chính
CoLLM [5]	MLP pointwise, mỗi embedding thành một soft token	Đơn giản; baseline mạnh	Ánh xạ độc lập; thiếu cơ chế tổng hợp và chọn lọc thích nghi
Sell-aRec [14]	Học tương phản	Căn chỉnh trực tiếp hai không gian biểu diễn	Khác backbone; khó quy chênh lệch số liệu hoàn toàn cho cơ chế
Bin-LLM [16]	Mã hóa nhị phân	Giao diện đơn giản với LLM; không cần soft token	Có thể mất thông tin khi rời rạc hóa
CoRA [17]	Sinh cập nhật trọng số theo mẫu	Cá nhân hóa sâu trong tính toán của LLM	Cần thiệp vào trọng số thay vì không gian đầu vào
ILM [7]	Q-Former và cross-attention	Có khả năng chọn lọc và tổng hợp tín hiệu	Chưa báo cáo AUC/uAUC theo thiết lập CoLLM

Chương 3

Phương pháp đề xuất

Chương này trình bày kiến trúc CoQLLM, cơ sở thiết kế và quy trình huấn luyện của mô hình. Xuất phát từ hạn chế của phép ánh xạ pointwise bằng MLP trong CoLLM, luận văn khảo sát Q-Former như một cầu nối căn chỉnh có khả năng tổng hợp nhiều nguồn tín hiệu cộng tác trước khi chuyển chúng thành soft token cho LLM. Các thành phần của mô hình được mô tả lần lượt từ kiến trúc tổng thể, mô-đun MF, cầu nối Q-Former và cơ chế soft token đến các kỹ thuật huấn luyện bổ sung và quy trình tối ưu ba giai đoạn.

3.1 Kiến trúc tổng thể

Bài toán. Luận văn xem nhiệm vụ gợi ý dưới dạng dự đoán nhị phân. Với người dùng u , lịch sử tương tác của người dùng và một sản phẩm mục tiêu i , mô hình ước lượng khả năng người dùng thích sản phẩm đó và biểu diễn đầu ra của LLM dưới dạng câu trả lời “Yes” hoặc “No”. Đây là bài toán phân loại nhị phân, được đánh giá chủ yếu bằng AUC và uAUC (chi tiết ở Chương 4).

CoQLLM gồm ba khối chính, minh họa ở Hình 3.1:

1. **Mô-đun phân rã ma trận (MF)** cung cấp embedding cộng tác cho người dùng, sản phẩm mục tiêu và các sản phẩm trong lịch sử

tương tác.

2. **Cầu nối Q-Former** biến đổi mỗi véc-tơ cộng tác thành các soft token bằng một tập truy vấn học được (self-attention giữa các truy vấn và cross-attention tới véc-tơ cộng tác).
3. **Mô hình ngôn ngữ lớn (LLM)** nhận các soft token cộng tác cùng prompt văn bản, kết hợp chúng qua self-attention và thực hiện dự đoán “Yes/No”.


Phần lớn tham số của hệ thống được giữ cố định trong quá trình huấn luyện. Cả MF lẫn backbone LLM đều được đóng băng, trong khi Q-Former, các lớp chiếu và LoRA [9] được cập nhật ở các giai đoạn tương ứng. Tín hiệu cộng tác chỉ đi vào LLM qua soft token trong không gian đầu vào, không thông qua cơ chế sinh trọng số theo từng mẫu. Thiết kế này tách tương đối rõ vai trò của mô hình cộng tác, cầu nối căn chỉnh và mô hình ngôn ngữ, qua đó thuận lợi cho việc phân tích đóng góp của từng thành phần.

3.2 Mô-đun phân rã ma trận

Mô-đun MF đóng vai trò cung cấp biểu diễn cộng tác đầu vào cho CoQLLM. Từ ma trận tương tác người dùng–sản phẩm, mô hình học các embedding $e_u, e_i \in \mathbb{R}^d$ sao cho mức độ tương thích giữa hai véc-tơ phản ánh sở thích của người dùng, đo bằng tích vô hướng $e_u^\top e_i$. MF được huấn luyện bằng mục tiêu xếp hạng cặp BPR [10] và được đóng băng trước khi tích hợp với các thành phần còn lại.

Ba nhóm tín hiệu được trích xuất từ MF gồm: (i) embedding người dùng e_u ; (ii) embedding sản phẩm mục tiêu e_i ; và (iii) embedding của các sản phẩm trong lịch sử tương tác $\{e_{i'} : i' \in \mathcal{H}_u\}$.

Việc huấn luyện MF tách biệt khỏi Q-Former và LLM nhằm giữ cố định nguồn tín hiệu cộng tác trong các thí nghiệm phía sau. Cách thiết kế này



Hình 3.1: Kiến trúc tổng quan của CoQLLM. Mô-đun MF cung cấp biểu diễn cộng tác; cầu nối Q-Former căn chỉnh tín hiệu này thành các soft token được chèn vào prompt; LLM thực hiện dự đoán. Chỉ Q-Former, các lớp chiếu và bộ chuyển thể LoRA được cập nhật theo từng giai đoạn huấn luyện.

giúp giảm sự đan xen giữa thay đổi của mô hình cộng tác và thay đổi của cầu nối cân chỉnh, từ đó thuận lợi hơn khi phân tích nguyên nhân của các chênh lệch thực nghiệm. Trong phạm vi luận văn, MF được huấn luyện trên phần dữ liệu huấn luyện tương ứng của từng tập dữ liệu và sau đó giữ nguyên trong các giai đoạn tích hợp.

Việc giữ MF đóng băng trong các giai đoạn sau nhất quán với cấu hình mặc định của CoLLM [5]. Trong khảo sát của CoLLM, việc tiếp tục tinh chỉnh mô hình cộng tác cùng với lớp chiếu có thể cải thiện nhẹ kết quả trong phần lớn trường hợp, nhưng làm tăng đáng kể chi phí huấn luyện (khoảng năm lần trên MovieLens-1M) và làm chậm hội tụ; vì vậy đóng băng là một đánh đổi hợp lý giữa hiệu năng và chi phí. Bên cạnh đó, một mô hình cộng tác đã được huấn luyện tốt còn đóng vai trò tiên nghiệm (prior) và ràng buộc cho quá trình học soft token. Quan trọng hơn đối với mục tiêu phân tích của luận văn, việc cố định MF cho phép quy phần trần của uAUC về chất lượng embedding của MF ở nhóm người dùng/sản phẩm ngoại (Mục 4.5.2), thay vì để đóng góp của MF và của cầu nối cân chỉnh trộn lẫn với nhau. Việc mở băng và tinh chỉnh đồng thời MF được ghi nhận như một hướng khảo sát trong tương lai.

3.3 Cầu nối Q-Former

3.3.1 Động cơ lựa chọn Q-Former

Mô-đun ánh xạ trong CoLLM [5] có dạng MLP hai lớp:

$$g_\phi(\mathbf{x}) = \mathbf{W}_2 \text{ReLU}(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2,$$

với $g_\phi : \mathbb{R}^d \rightarrow \mathbb{R}^{d_{\text{LLM}}}$. Phép biến đổi này được áp dụng độc lập trên từng embedding cộng tác và mỗi embedding tạo ra một soft token. Cần lưu ý rằng MLP đã là một phép biến đổi phi tuyến; hạn chế mà luận văn quan tâm không nằm ở tính tuyến tính hay phi tuyến, mà ở cách thông tin được

tổng hợp.

Thứ nhất, phép ánh xạ có tính pointwise: đầu ra ứng với một embedding được tính độc lập với các embedding còn lại trong cùng mẫu. Vì vậy, embedding người dùng, sản phẩm mục tiêu và lịch sử không được phối hợp ở phía mô-đun ánh xạ trước khi đi vào LLM. Thứ hai, mỗi embedding được cô đọng thành một soft token duy nhất, nên mô-đun không có một cơ chế riêng để học cách phân bổ mức độ chú ý khác nhau cho các nguồn tín hiệu cộng tác theo từng mẫu.

Q-Former cung cấp một cơ chế khác. Thay vì một phép chiếu cố định cho ra đúng một token, mỗi véc-tơ cộng tác được một *tập truy vấn học* được khai triển thành nhiều biểu diễn: các truy vấn có khởi tạo riêng và phối hợp với nhau qua self-attention, nên có thể chuyên biệt hóa để nắm các khía cạnh khác nhau của cùng một tín hiệu cộng tác. Đây là điểm khác biệt cốt lõi so với một hàm pointwise duy nhất.

Cần nói rõ giới hạn của lập luận này để tránh phóng đại. Lợi thế của Q-Former ở đây không đến từ khả năng nén như trong thị giác: mỗi sản phẩm được mã hóa từ *một* véc-tơ cộng tác duy nhất, nên cross-attention chủ yếu đóng vai một phép đọc có học đối với véc-tơ đó (chi tiết ở Mục 3.3.2). Sức mạnh của cầu nối vì thế nằm ở tập truy vấn học được, sự phối hợp qua self-attention và độ sâu của phép biến đổi, chứ không nằm ở việc gộp nhiều nguồn tín hiệu bên trong Q-Former.

3.3.2 Q-Former cho bài toán gợi ý

CoQLLM xây dựng cầu nối dựa trên kiến trúc Q-Former của BLIP-2 [6]. Mô hình sử dụng $Q = 8$ véc-tơ truy vấn học được $\mathbf{Q} \in \mathbb{R}^{Q \times d_{\text{model}}}$, với $d_{\text{model}} = 768$. Nhánh văn bản được khởi tạo từ `bert-base-uncased` và được sử dụng trong các mục tiêu căn chỉnh sản phẩm–văn bản ở giai đoạn tiền huấn luyện biểu diễn (Mục 3.5.1).

Trong mỗi lớp Q-Former, các truy vấn đi qua hai cơ chế attention:

1. *Self-attention* giữa các truy vấn với nhau, cho phép các truy vấn trao

đổi thông tin và phối hợp vai trò biểu diễn, mỗi truy vấn đảm nhận một khía cạnh khác nhau của tín hiệu cộng tác.

2. *Cross-attention* từ các truy vấn đến biểu diễn cộng tác của sản phẩm đang được mã hóa: các truy vấn cùng đọc một véc-tơ cộng tác đầu vào và biến đổi nó thành nhiều kênh biểu diễn khác nhau.

Đầu ra là khối truy vấn $\mathbf{Z} = \text{cf_q} \in \mathbb{R}^{B \times Q \times d_{\text{model}}}$, trong đó B là kích thước batch và $Q = 8$.

Trong CoQLLM, mỗi sản phẩm (sản phẩm mục tiêu và từng sản phẩm trong lịch sử) được Q-Former mã hóa *độc lập* từ một véc-tơ cộng tác thành Q soft token. Tín hiệu người dùng không đi vào Q-Former dưới dạng đầu vào cross-attention mà được đưa vào qua điều kiện hóa truy vấn (Mục 3.3.4); còn việc kết hợp thông tin *giữa* các sản phẩm được thực hiện ở lớp self-attention của LLM trên toàn bộ soft token, chứ không phải bên trong cầu nối.

Điều này dẫn tới một khác biệt so với BLIP-2. Trong thị giác, cross-attention nén hàng trăm patch thành số truy vấn nhỏ hơn nhiều, nên đóng vai trò nén chính. Trong CoQLLM, do đầu vào chỉ là một véc-tơ cộng tác cho mỗi lần mã hóa, cross-attention gần như một phép đọc có học đối với véc-tơ đó; điều tạo ra Q biểu diễn khác nhau chính là tập truy vấn học được (mỗi truy vấn khởi tạo riêng) cùng self-attention phối hợp giữa chúng. Vì vậy, luận văn xem *tập truy vấn học được và self-attention* – chứ không phải khả năng nén hay việc gộp nhiều nguồn bên trong Q-Former – là thành phần quan trọng của cầu nối căn chỉnh.

3.3.3 Tích hợp biểu diễn cộng tác qua soft token

Đầu ra $\mathbf{Z}$ của Q-Former được chiếu từ không gian d_{model} sang không gian embedding của LLM bằng lớp tuyến tính $W_{\text{proj}} \in \mathbb{R}^{d_{\text{model}} \times d_{\text{LLM}}}$. Kết quả là Q soft token được chèn vào prompt tại vị trí dành cho biểu diễn cộng tác.

Phần văn bản của prompt đánh dấu lịch sử và sản phẩm mục tiêu bằng các token chuyên dụng. Một token định danh riêng được sử dụng cho vị trí soft token nhằm tránh phụ thuộc vào <unk> hoặc các token có chức năng khác trong từ vựng gốc. Sau lớp chiếu, một lớp chuẩn hóa (LayerNorm) được áp dụng để giữ thang độ của soft token tương thích hơn với embedding văn bản của LLM.

Nhờ cơ chế này, tín hiệu cộng tác được đưa vào cùng không gian đầu vào với văn bản mà không cần thay đổi trực tiếp trọng số backbone LLM theo từng mẫu. Đây là điểm khác với CoRA [17], nơi biểu diễn cộng tác được sử dụng để sinh cập nhật trọng số hạng thấp cho các lớp attention. CoQLLM chủ động giới hạn đường tích hợp ở soft token để giữ LLM hoàn toàn đóng băng và tập trung phân tích vai trò của cầu nối căn chỉnh. Trên nền đường soft token này, luận văn bổ sung hai kỹ thuật huấn luyện – điều kiện hóa truy vấn theo người dùng (Mục 3.3.4) và mục tiêu bảo toàn thứ tự trong từng người dùng (Mục 3.3.5) – nhằm cải thiện lần lượt AUC và uAUC.

3.3.4 Điều kiện hóa truy vấn theo người dùng

Trong cấu hình cơ sở, tập truy vấn $\mathbf{Q}$ là tham số dùng chung cho mọi mẫu. Để tăng khả năng thích nghi theo người dùng, luận văn bổ sung một phép dịch chuyển phụ thuộc vào embedding người dùng trước khi đưa truy vấn vào Q-Former:

$$\tilde{\mathbf{Q}} = \mathbf{Q} + g_u(e_u), \quad (3.1)$$

trong đó g_u là một lớp chiếu tuyến tính từ không gian MF sang không gian truy vấn, được *khởi tạo bằng không* (zero-init). Với cách khởi tạo này, ở bước đầu cơ chế không làm thay đổi truy vấn gốc, tức $\tilde{\mathbf{Q}} = \mathbf{Q}$; mức dịch chuyển chỉ được học khi mang lại lợi ích cho hàm mục tiêu trong quá trình huấn luyện.

Về mặt trực giác, thành phần $g_u(e_u)$ tạo ra một mức điều chỉnh riêng

theo người dùng. Vì phân dịch chuyển *thay đổi giữa các người dùng* nhưng *không đổi trong phạm vi một người dùng*, cơ chế này có thể nâng khả năng phân biệt giữa các người dùng và do đó tác động tích cực đến AUC toàn cục, trong khi tác động lên uAUC – vốn bất biến với dịch chuyển mức nền riêng theo từng người dùng – có thể nhỏ hơn. Giả thuyết này được đối chiếu với kết quả thực nghiệm ở Chương 4. Vì g_u chỉ xuất hiện khi bật cờ và được khởi tạo bằng không, cơ chế tương thích với checkpoint cũ và chỉ cần huấn luyện lại Bước 2 của Giai đoạn 3.

3.3.5 Hàm mất mát bảo toàn thứ hạng theo người dùng

Hàm mất mát mặc định trong giai đoạn tinh chỉnh CTR là entropy chéo nhị phân (BCE) trên nhãn “Yes”/“No”. BCE tối ưu khả năng phân loại từng mẫu nhưng không trực tiếp tối ưu thứ tự tương đối giữa các sản phẩm của cùng một người dùng, trong khi uAUC đo chính đặc tính xếp hạng nội bộ này.

Để bổ sung tín hiệu xếp hạng, luận văn sử dụng một mục tiêu BPR theo cặp trong phạm vi từng người dùng (*align-rank loss*), áp trực tiếp lên soft token cộng tác đã căn chỉnh (trước khi vào LLM) thông qua một đầu ra phụ cũng khởi tạo bằng không:

$$\mathcal{L} = \mathcal{L}_{\text{BCE}} + \lambda \sum_u \sum_{(i^+, i^-) \in \mathcal{P}_u} -\log \sigma\left(\frac{1}{\tau}(s_u(i^+) - s_u(i^-))\right), \quad (3.2)$$

trong đó $s_u(\cdot)$ là điểm xếp hạng được sinh từ soft token cộng tác đã căn chỉnh, $\mathcal{P}_u$ là tập các cặp dương–âm của cùng người dùng u , σ là hàm sigmoid, τ là nhiệt độ và λ là trọng số của thành phần xếp hạng.

Mục tiêu phụ được áp trực tiếp lên biểu diễn cộng tác sau căn chỉnh, thay vì chỉ lên logit “Yes/No” của LLM, nhằm buộc bản thân câu hỏi giữ đúng thứ tự giữa sản phẩm dương và âm trong từng người dùng. Để tạo

đủ cặp dương–âm trong một batch, quá trình huấn luyện sử dụng lấy mẫu theo nhóm người dùng (*user-grouped batch*) và mục tiêu được kích hoạt ở Bước 2 của Giai đoạn 3 (nơi Q-Former và lớp chiếu được huấn luyện). Do đầu ra phụ khởi tạo bằng không, các epoch đầu gần như trung tính và tác động của mục tiêu xếp hạng hiện dần về sau. Đây là một siêu tham số phụ thuộc tập dữ liệu: nó cải thiện uAUC trên tập còn nhiều dư địa xếp hạng trong từng người dùng (Amazon-Book) và gần như trung tính khi uAUC đã bão hòa (MovieLens-1M).

3.4 Biểu diễn cộng tác đa token

Do Q-Former sử dụng $Q = 8$ truy vấn học được, đầu ra của nó là Q véc-tơ. CoQLLM chiếu toàn bộ Q véc-tơ này qua lớp chiếu và đưa vào LLM như Q soft token riêng biệt cho mỗi sản phẩm (sản phẩm mục tiêu và từng sản phẩm trong lịch sử). Đây là *hệ quả trực tiếp* của việc dùng nhiều truy vấn, không phải một mô-đun được thiết kế thêm: giữ nguyên cả Q véc-tơ cho phép mỗi truy vấn truyền một khía cạnh biểu diễn khác nhau tới LLM, thay vì phải hợp nhất về một véc-tơ duy nhất trước khi đi vào mô hình ngôn ngữ.

Điểm này tạo một khác biệt so với CoLLM [5], vốn cô đọng mỗi véc-tơ cộng tác thành đúng một soft token. Với cùng số nguồn cộng tác, CoQLLM đưa vào LLM số soft token gấp Q lần, tức bằng thông biểu diễn cao hơn. Luận văn ghi nhận đây là một *yếu tố gây nhiễu* (confound) cần lưu ý khi so sánh với CoLLM, chứ không xem việc dùng nhiều token là một đóng góp riêng.

Việc tách riêng ảnh hưởng của số lượng soft token (một token so với Q token) dưới cùng một backbone chưa được thực hiện trong luận văn; đây là một ablation còn để ngỏ, được ghi nhận minh bạch ở Mục 4.7.

3.5 Huấn luyện ba giai đoạn

CoQLLM được huấn luyện theo ba giai đoạn nối tiếp, theo quy trình của CoLLM [5] với điều chỉnh cho phù hợp với kiến trúc Q-Former. Quy trình kế thừa tinh thần tách biệt giữa học biểu diễn cộng tác, căn chỉnh với không gian ngôn ngữ và tinh chỉnh cho nhiệm vụ gợi ý.

3.5.1 Tiền huấn luyện biểu diễn

Giai đoạn đầu tập trung giúp Q-Former học mối quan hệ giữa biểu diễn cộng tác và thông tin văn bản, thông qua bốn mục tiêu:

- *Căn chỉnh sản phẩm–văn bản (ITC)*: tăng độ tương đồng giữa biểu diễn Q-Former của một sản phẩm (từ embedding MF) và biểu diễn văn bản tương ứng (tên phim, thể loại). Đây là mục tiêu căn chỉnh chính.
- *So khớp sản phẩm–văn bản (ITM)*: phân loại nhị phân một cặp sản phẩm–văn bản là tương ứng hay không tương ứng.
- *Sinh văn bản có điều kiện (ITG)*: sử dụng biểu diễn sản phẩm để hỗ trợ sinh mô tả văn bản.
- *Tương phản người dùng–sản phẩm*: đưa các cặp tương tác dương lại gần nhau và tách các cặp âm trong không gian biểu diễn.

Một vấn đề thực tế là sự mất cân bằng giữa số cặp người dùng–sản phẩm và số cặp sản phẩm–văn bản. Trên MovieLens-1M, số cặp người dùng–sản phẩm dương khoảng 888 nghìn, trong khi số cặp sản phẩm–văn bản chỉ khoảng 3 nghìn (tỉ lệ khoảng 0,34%). Nếu lấy mẫu trực tiếp từ toàn bộ dữ liệu, các mục tiêu ITC/ITM/ITG có thể được kích hoạt quá ít trong từng batch – điều kiện “ít nhất hai mẫu cùng loại” hiếm khi được thỏa – và gradient từ mục tiêu người dùng–sản phẩm chiếm ưu thế.

Để giảm mất cân bằng, luận văn áp dụng hai điều chỉnh, tổng hợp ở Bảng 3.1:

Bảng 3.1: Hai điều chỉnh cân bằng dữ liệu Giai đoạn 1

Điều chỉnh	Mức áp dụng	Mục đích
Giới hạn số cặp người dùng–sản phẩm ở mức 20.000	Dữ liệu	Tăng tỉ lệ mẫu sản phẩm–văn bản trong batch, giúp các mục tiêu ITC/ITM/ITG được kích hoạt thường xuyên hơn
Giảm trọng số mất mát người dùng–sản phẩm từ 1,0 xuống 0,5	Hàm mất mát	Cân bằng cường độ gradient giữa các mục tiêu

Danh sách cặp người dùng–sản phẩm kế thừa thứ tự sắp theo thời gian của dữ liệu gốc, nên việc lấy phần đầu danh sách sẽ thiên lệch về các tương tác sớm. Để tránh thiên lệch này, danh sách được xáo trộn ngẫu nhiên với hạt giống cố định trước khi cắt, biến giới hạn 20.000 thành một mẫu ngẫu nhiên đồng nhất mà vẫn bảo đảm tính tái lập.

3.5.2 Tiền huấn luyện sinh

Ở giai đoạn thứ hai, Q-Former và lớp chiếu được huấn luyện với mục tiêu sinh ngôn ngữ. Từ biểu diễn cộng tác đã qua Q-Former, mô hình học tạo ra các soft token mà LLM đóng băng có thể khai thác để sinh văn bản mô tả sản phẩm. Có thể xem đây là bước căn chỉnh đầu ra của Q-Former với không gian embedding mà LLM sử dụng trong quá trình sinh.

3.5.3 Tinh chỉnh CTR

Giai đoạn cuối theo quy trình hai bước của CoLLM [5].

Bước 1 – Tinh chỉnh LoRA chỉ với thông tin văn bản. LoRA được huấn luyện bằng prompt chỉ chứa tên sản phẩm, thể loại và lịch sử ở dạng văn bản, chưa đưa tín hiệu cộng tác vào. Mục tiêu của bước này là giúp LLM thích nghi với nhiệm vụ dự đoán nhị phân từ thông tin ngôn ngữ và ổn định hóa mô hình trước khi tiếp nhận soft token cộng tác.

Bước 2 – Tinh chỉnh cầu nối căn chỉnh với tín hiệu cộng tác. Mô hình được khởi tạo từ checkpoint của Bước 1. LoRA được giữ cố định, trong khi Q-Former và các lớp chiều được cập nhật để học cách đưa biểu diễn cộng tác vào LLM dưới dạng soft token – tách bạch phần “ngôn ngữ” (LoRA, học ở Bước 1) khỏi phần “cộng tác” (cầu nối căn chỉnh, học ở Bước 2). Đây cũng là bước duy nhất kích hoạt hai kỹ thuật điều kiện hóa truy vấn theo người dùng (Mục 3.3.4) và, khi cấu hình cho phép, mục tiêu bảo toàn thứ hạng trong từng người dùng (Mục 3.3.5). Nhãn giám sát là “Yes”/“No” tương ứng với nhãn CTR, và checkpoint tốt nhất được chọn theo uAUC trên tập kiểm định.

So với mô-đun chiều MLP của CoLLM, Q-Former làm tăng chi phí huấn luyện do có nhiều lớp attention và tham số hơn. Vì tín hiệu cộng tác chỉ đi qua đường soft token và không sinh trọng số theo từng mẫu, LLM được giữ nguyên hoàn toàn khi suy luận. Luận văn xem đây là một đánh đổi có chủ đích để khảo sát khả năng căn chỉnh biểu diễn tốt hơn, thay vì giả định chi phí tăng thêm là “không đáng kể”. Chi tiết về số tham số và thời gian huấn luyện được trình bày ở Chương 4.

3.6 Tổng kết chương

Chương này đã trình bày CoQLLM như một kiến trúc tích hợp tín hiệu cộng tác vào LLM thông qua cầu nối Q-Former. Khác với phép ánh xạ pointwise bằng MLP của CoLLM, Q-Former tổng hợp nhiều nguồn tín hiệu

bằng các truy vấn học được và attention trước khi chuyển chúng thành soft token. Trên nền kiến trúc này, luận văn bổ sung điều kiện hóa truy vấn theo người dùng và mục tiêu bảo toàn thứ hạng trong từng người dùng – cải thiện lần lượt AUC và uAUC. Chương cũng ghi nhận biểu diễn đa token như một hệ quả trực tiếp của thiết kế nhiều truy vấn, đồng thời là yếu tố cần lưu ý khi so sánh với CoLLM. Chương tiếp theo đánh giá các thiết kế trên thông qua kết quả thực nghiệm.

Chương 4

Thực nghiệm và kết quả

Chương này trình bày thiết lập thực nghiệm, kết quả đánh giá CoQLLM so với các baseline, phân tích ablation và thảo luận. Tất cả số liệu trong chương được báo cáo trên một lần chạy duy nhất (một seed); khoảng tin cậy chưa được tính – đây là một hạn chế được thừa nhận (Mục 4.7).

4.1 Thiết lập thực nghiệm

4.1.1 Tập dữ liệu

Thực nghiệm được thực hiện trên hai tập dữ liệu chuẩn theo quy trình của CoLLM [5].

MovieLens-1M [18] gồm khoảng 1 triệu đánh giá từ 6.040 người dùng cho 3.706 phim, mỗi đánh giá là số sao từ 1 đến 5. Đánh giá được nhị phân hóa thành nhãn CTR: ≥ 4 sao được coi là nhấp (click), còn lại là không nhấp.

Amazon-Book [17] là một tập dữ liệu thưa hơn nhiều so với MovieLens-1M, theo đúng phân chia dùng trong CoLLM và CoRA. Tập này có khoảng 23 nghìn người dùng và 34 nghìn sản phẩm sách, với độ thưa và tỉ lệ người dùng/sản phẩm nguội cao hơn hẳn – đây chính là điều kiện để kiểm chứng câu nói CF-LLM trên miền khó, nơi tín hiệu cộng tác yếu và LLM/Q-Former có nhiều dư địa đóng góp. Nhãn CTR được nhị phân hóa tương

tự. Việc bổ sung Amazon-Book cho phép đánh giá khả năng tổng quát của CoQLLM ngoài miền phim và làm nổi bật vai trò của mục tiêu bảo toàn thứ tự trong từng người dùng (Mục 3.3.5).

4.1.2 Phân chia dữ liệu và thiết lập đánh giá

Theo quy trình của CoLLM [5], dữ liệu được sắp xếp theo thời gian và phân chia thành tập huấn luyện, kiểm định và kiểm tra theo tỉ lệ 8:1:1. Để đảm bảo so sánh công bằng, các siêu tham số được chọn dựa trên tập kiểm định và số liệu cuối cùng được báo cáo trên tập kiểm tra.

4.1.3 Mô hình so sánh

Baseline chính:

- **CoLLM** [5]: tích hợp tín hiệu cộng tác vào LLM qua MLP pointwise (mỗi véc-tơ cộng tác thành một token); cùng giao thức, cùng tập dữ liệu. Đây là baseline chính để đánh giá đóng góp của cầu nối Q-Former. Trên MovieLens-1M, luận văn đối chiếu với hai biến thể CoLLM-MF và CoLLM-DIN.
- **BinLLM** [16]: mã hóa nhị phân tín hiệu cộng tác vào LLM – SOTA gần nhất theo quy trình này, có mặt trên cả hai tập dữ liệu.

Baseline bổ sung:

- **CoRA** [17]: đại diện hướng *sinh trọng số* (không soft token). Trên Amazon-Book, biến thể CoRA-MF được đưa vào bảng so sánh như một điểm tham chiếu cho hướng thiết kế khác với CoQLLM (Mục 2.3.4).
- **MF** [10] và **DIN**: các mô hình lọc cộng tác thuần (không LLM), làm mốc sàn để đo phần đóng góp thêm của cầu nối CF-LLM.
- **SellaRec** [14]: học tương phản InfoNCE, backbone Qwen2-7B-Base; lưu ý: *CoQLLM dùng Vicuna-7B-v1.5, khác họ backbone, nên so*

sánh trực tiếp về số liệu bị giới hạn – được thảo luận như baseline không đồng nhất.

- **ILM** [7]: Q-Former cho gợi ý; *lưu ý: ILM không báo cáo AUC/uAUC cho bài toán CTR, nên không thể so sánh trực tiếp về số liệu; được đề cập trong phần thảo luận.*

Giao thức lấy số liệu baseline. Trên MovieLens-1M, số liệu CoLLM/BinLLM lấy theo quy trình CoLLM-parity. Trên Amazon-Book, số liệu CoLLM-MF/BinLLM/CoRA-MF lấy từ lần chạy lại (re-run) trong CoRA [17] để đảm bảo cùng phân chia dữ liệu. Cần lưu ý một khác biệt quy trình: CoQLLM chọn checkpoint tốt nhất theo **uAUC**, trong khi CoLLM/CoRA chọn theo **AUC**; điều này được ghi chú trực tiếp ở bảng kết quả.

4.1.4 Chỉ số đánh giá

Luận văn dùng hai độ đo chính theo quy trình CoLLM:

- **AUC** (Area Under the ROC Curve): đánh giá khả năng phân biệt tổng thể trên toàn tập kiểm tra – xác suất để điểm dự đoán của mẫu dương cao hơn mẫu âm.
- **uAUC** (user-level AUC): AUC được tính riêng trong phạm vi từng người dùng rồi lấy trung bình. uAUC đánh giá chất lượng xếp hạng *trong từng người dùng* và bất biến với các phép biến đổi đơn điệu theo từng người dùng.

Bổ sung: Accuracy và F1 (độ đo phân loại nhị phân), Precision@K và NDCG@K (độ đo xếp hạng top-K), và cosine similarity trước/sau căn chỉnh (đo mức độ thu hẹp khoảng cách ngữ nghĩa CF-LLM).

4.1.5 Chi tiết cài đặt

- **LLM backbone**: Vicuna-7B-v1.5 [8] (tinh chỉnh chỉ dẫn trên nền Llama-2) – cùng lớp backbone Vicuna instruction-tuned mà CoLLM

sử dụng (Vicuna-7B-v1.1), nhằm bảo đảm so sánh công bằng; đóng băng hoàn toàn; khuôn mẫu chỉ dẫn USER/ASSISTANT.

- **MF**: phân rã ma trận BPR [10], chiều ẩn $d = 256$, được huấn luyện và đóng băng trước khi tích hợp.
- **Q-Former**: $Q = 8$ truy vấn, $d_{\text{model}} = 768$, 8 đầu attention, 4 lớp; nhánh văn bản khởi tạo từ **bert-base-uncased**.
- **LoRA** [9]: hạng $r = 8$, $\alpha = 16$, dropout 0,05, áp dụng trên các lớp $[q, v]$ của LLM.
- **Kỹ thuật SOTA**: điều kiện hóa truy vấn theo người dùng bật trên cả hai tập dữ liệu; hàm mất mát bảo toàn thứ tự ($\lambda = 0,2$, kèm lấy mẫu theo nhóm người dùng) bật trên Amazon-Book, tắt trên MovieLens-1M.
- **Chọn checkpoint**: theo uAUC trên tập kiểm định (khác CoLLM/CoRA chọn theo AUC – xem ghi chú bảng kết quả).
- **Optimizer**: AdamW; learning rate tùy giai đoạn (Bước 2 Giai đoạn 3 dùng 3×10^{-5} , giảm theo lịch cosine về 3×10^{-6}).
- **Phần cứng**: một GPU NVIDIA A100 80GB.
- **Tham số huấn luyện được**: chỉ LoRA (khoảng vài triệu tham số trên các lớp $[q, v]$ của backbone 7 tỉ tham số), cầu nối Q-Former và các lớp chiếu được cập nhật; MF và LLM đóng băng. Không có tham số sinh trọng số. Tổng số tham số huấn luyện được rất nhỏ so với 7 tỉ tham số đóng băng của LLM, phản ánh thiết kế tinh chỉnh hiệu quả tham số.
- **Thời gian huấn luyện**: mỗi epoch mất khoảng 4–6 phút trên phần cứng nói trên (0,65–0,84 giây/iteration tùy giai đoạn).

4.2 Kết quả tổng thể

Bảng 4.1 và Bảng 4.2 so sánh CoQLLM với CoLLM, BinLLM và các baseline trên MovieLens-1M và Amazon-Book theo AUC và uAUC.

Bảng 4.1: Kết quả trên MovieLens-1M (quy trình CoLLM-parity). CoQLLM báo cáo hai cấu hình: *vanilla* (chỉ soft token) và *+ điều kiện hóa* (cấu hình đề xuất). CoQLLM chọn checkpoint theo uAUC.

Phương pháp	AUC	uAUC
MF (chỉ cộng tác) [10]	0,6482	0,6361
DIN (chỉ cộng tác)	0,7166	0,6459
CoLLM-MF [5]	0,7295	0,6875
CoLLM-DIN [5]	0,7243	0,6897
BinLLM [16]	0,7425	0,6956
CoQLLM (vanilla)	0,7335	0,7009
CoQLLM (+ điều kiện hóa)	0,7475	0,6968

MovieLens-1M. Cấu hình đề xuất (+ điều kiện hóa) đạt AUC 0,7475 và uAUC 0,6968, vượt BinLLM trên cả hai độ đo (0,7425/0,6956) và vượt rõ CoLLM-MF/CoLLM-DIN. Đây là điểm đáng chú ý nhất: nhiều phương pháp CF-LLM chỉ thắng một trong hai độ đo. So với cấu hình vanilla, điều kiện hóa truy vấn theo người dùng nâng AUC từ 0,7335 lên 0,7475 (+0,014) trong khi uAUC gần như không đổi (0,7009 $\rightarrow$ 0,6968, chênh lệch nằm trong biên độ nhiễu) – đúng như phân tích ở Mục 4.3: phân dịch theo người dùng chủ yếu nâng khả năng phân biệt *giữa* các người dùng (AUC), gần như trung tính với xếp hạng *trong* người dùng (uAUC).

Amazon-Book. Đây là miền thừa và khó hơn. Với điều kiện hóa truy vấn theo người dùng (Run-1), CoQLLM đạt AUC 0,8147 và uAUC 0,5958 – vượt cả CoLLM-MF và BinLLM (theo lần chạy lại của CoRA) trên cả hai độ đo. Bổ sung hàm mất mát bảo toàn thứ tự (Run-2) nâng uAUC lên 0,6062 (+0,0104) trong khi AUC gần như đứng yên ($-0,0015$) – đúng thiết

Bảng 4.2: Kết quả trên Amazon-Book. Số liệu CoLLM-MF/BinLLM/CoRA-MF lấy từ lần chạy lại trong CoRA [17] (chọn checkpoint theo AUC); CoQLLM chọn theo uAUC. uAUC tính trên 2.486 người dùng tập kiểm tra. Run-1 = + điều kiện hóa; Run-2 = thêm bảo toàn thứ tự.

Phương pháp	AUC	uAUC
CoLLM-MF [5] (CoRA re-run)	0,8021	0,5782
BinLLM [16] (CoRA re-run)	0,8157	0,5724
CoRA-MF [17] (sinh trọng số)	0,8179	0,6262
CoQLLM (+ điều kiện hóa, Run-1)	0,8147	0,5958
CoQLLM (+ bảo toàn thứ tự, Run-2)	0,8132	0,6062

kế: tổn thất này tác động vào thứ tự trong từng người dùng chứ không ảnh hưởng đến khả năng phân biệt giữa các người dùng. Con số 0,6062 đưa CoQLLM vào vùng cạnh tranh với CoRA-MF (0,6262), vốn dùng cơ chế sinh trọng số khác hẳn.

Về quy trình so sánh. CoQLLM chọn checkpoint theo **uAUC**, còn CoLLM/CoRA theo **AUC**; do đó uAUC của CoQLLM là uAUC-tối-ưu-trên-frontier (lợi thế nhẹ) và cần được đọc kèm khác biệt này. Trên Amazon-Book, số liệu CoLLM/BinLLM có sai khác đáng kể giữa các lần chạy lại trong tài liệu (uAUC dao động $\approx 0,57$ – $0,63$ tùy cấu hình huấn luyện và cỡ tập người dùng nhiều); luận văn vì thế định vị kết quả là “cạnh tranh/vượt baseline dưới quy trình có kiểm soát” thay vì đuổi theo một con số tuyệt đối.

4.3 Phân tích khác biệt AUC–uAUC

uAUC tính AUC trong phạm vi từng người dùng rồi lấy trung bình, nên bất biến với các phép biến đổi đơn điệu riêng theo người dùng. Điều này dẫn đến một đặc điểm quan trọng: tín hiệu cộng tác nếu chỉ giúp phân biệt giữa các người dùng (thay đổi *mức nền* điểm dự đoán của mỗi người dùng) thì cải thiện AUC nhưng không cải thiện uAUC. Mô hình cần học thứ tự xếp hạng *trong* từng người dùng – cặp sản phẩm nào người dùng này thích hơn – thay vì chỉ phân biệt người dùng với nhau.

Đặc điểm này được xác nhận trực tiếp qua phân rã warm/cold (Mục 4.5.2). Trên cả hai tập dữ liệu, uAUC ở nhóm người dùng *ấm* (warm, MF có tín hiệu) cao hơn hẳn nhóm *nguội* (cold): trên Amazon-Book, uAUC warm đạt 0,6238 – gần chạm CoRA-MF (0,6262) – trong khi uAUC cold chỉ 0,5258, tức xấp xỉ mức ngẫu nhiên. Nhóm cold kéo trung bình toàn tập xuống 0,6062. Điều này cho thấy trần của uAUC không nằm ở cầu nối Q-Former (nếu Q-Former yếu thì AUC cũng phải sập, nhưng AUC vẫn cao $\approx 0,81$) mà ở *chất lượng véctơ cộng tác của MF cho người dùng/sản phẩm nguội*. Đây là căn cứ để định hướng cải thiện uAUC về phía MF teacher (Mục 5.4) thay vì tinh chỉnh thêm kiến trúc cầu nối.

4.4 Thí nghiệm loại bỏ thành phần

Bảng 4.3 trình bày phân tích ablation các thành phần của CoQLLM.

Bảng 4.3 tách biệt đóng góp của hai kỹ thuật huấn luyện bằng cách bật/tắt từng cơ chế trên nền cầu nối soft token, trên cả hai tập dữ liệu.

Đọc bảng ablation. Hai kỹ thuật tác động lên hai độ đo khác nhau, đúng như thiết kế. Trên MovieLens-1M, điều kiện hóa truy vấn theo người dùng chủ yếu tác động lên *AUC* (+0,014), gần trung tính với uAUC. Trên Amazon-Book, hàm mất mát bảo toàn thứ tự chủ yếu tác động lên *uAUC* (+0,0104), gần trung tính với AUC. Sự phân đôi này giải thích vì sao mỗi tập dữ liệu bật cơ chế khác nhau: trên MovieLens-1M uAUC đã gần bão

Bảng 4.3: Ablation hai kỹ thuật huấn luyện. Trên MovieLens-1M: bật điều kiện hóa truy vấn theo người dùng. Trên Amazon-Book: bật điều kiện hóa truy vấn theo người dùng (Run-1) rồi thêm hàm mất mát bảo toàn thứ tự (Run-2). Tất cả trên nền soft token; chọn checkpoint theo uAUC.

Tập dữ liệu	Cấu hình	AUC	uAUC
MovieLens-1M	Soft token (vanilla)	0,7335	0,7009
MovieLens-1M	+ điều kiện hóa	0,7475	0,6968
Amazon-Book	+ điều kiện hóa (Run-1)	0,8147	0,5958
Amazon-Book	+ bảo toàn thứ tự (Run-2)	0,8132	0,6062

hòa ($\approx 0,70$) nên hàm mất mát bảo toàn thứ tự không còn dư địa; trên Amazon-Book uAUC còn thấp ($\approx 0,59$) nên tổn thất xếp hạng trong từng người dùng phát huy tác dụng. Việc bật cơ chế theo từng tập dữ liệu vì thế là một *siêu tham số hợp lệ theo miền*, không phải sự bất nhất về phương pháp.

Các ablation chưa thực hiện. Do giới hạn tài nguyên, một số ablation vẫn còn để ngỏ và được ghi nhận minh bạch như hạn chế (Mục 4.7): (i) thay cầu nối Q-Former bằng một bộ chiếu *attention-MLP* (MLP có self-attention nhưng không có truy vấn học được) để cô lập đóng góp của *cấu trúc Q-Former* khỏi phần phi tuyến + attention đơn thuần; (ii) bật/tắt riêng biểu diễn đa token dưới cùng backbone Vicuna; (iii) ablation hàm mất mát bảo toàn thứ tự trên MovieLens-1M (kỳ vọng trung tính/âm vì uAUC đã bão hòa). Luận văn không điền số ước lượng cho các hàng này.

4.5 Phân tích bổ sung

4.5.1 Khoảng cách ngữ nghĩa

Để kiểm chứng rằng cầu nối Q-Former thực sự thu hẹp khoảng cách ngữ nghĩa giữa không gian cộng tác và không gian LLM, luận văn đo cosine similarity giữa: (i) véc-tơ cộng tác thô (đầu ra MF) và embedding token LLM tương ứng trước khi huấn luyện cầu nối; (ii) soft token đầu ra Q-Former và embedding token LLM sau khi huấn luyện. Kết quả kỳ vọng: cosine similarity tăng sau huấn luyện, cho thấy Q-Former thực sự căn chỉnh không gian cộng tác về phía không gian ngữ nghĩa LLM.

4.5.2 Phân tích theo nhóm warm/cold

Để kiểm chứng động lực cold-start, luận văn phân rẽ tập kiểm tra thành hai nhóm: người dùng *ấm* (warm – có embedding MF, tức MF đã “thấy” người dùng/sản phẩm trong huấn luyện) và người dùng *nguội* (cold – MF không có embedding, phải dùng đại diện mặc định). Bảng 4.4 trình bày AUC/uAUC theo từng nhóm trên cả hai tập dữ liệu.

Kết quả nhất quán trên cả hai tập dữ liệu: nhóm warm đạt uAUC cao hơn hẳn nhóm cold (0,7254 vs 0,5969 trên MovieLens-1M; 0,6238 vs 0,5258 trên Amazon-Book). Trên Amazon-Book, uAUC nhóm warm (0,6238) gần chạm CoRA-MF (0,6262), trong khi nhóm cold xấp xỉ mức ngẫu nhiên. Điều này khẳng định uAUC bị chặn trên bởi *chất lượng véc-tơ cộng tác cho người dùng/sản phẩm nguội* chứ không phải bởi cầu nối: ở nhóm warm – nơi MF cung cấp tín hiệu tốt – CoQLLM khai thác hiệu quả và tiệm cận baseline mạnh nhất. Nhận định này khớp với phân tích khác biệt AUC/uAUC (Mục 4.3) và chỉ ra hướng cải thiện tiếp theo nằm ở MF teacher trên nhóm cold (Mục 5.4).

Bảng 4.4: Phân rã warm/cold trên tập kiểm tra (cấu hình đề xuất). Amazon-Book dùng Run-2 (+ bảo toàn thứ tự).

Tập dữ liệu	Nhóm	#người dùng	AUC	uAUC
MovieLens-1M	toàn bộ	7.331	0,7475	0,6968
MovieLens-1M	warm	4.153	0,7787	0,7254
MovieLens-1M	cold	3.178	0,7030	0,5969
Amazon-Book	toàn bộ	2.486	0,8132	0,6062
Amazon-Book	warm	1.648	0,8190	0,6238
Amazon-Book	cold	630	0,7928	0,5258

4.6 Thảo luận

4.6.1 Đối chiếu với ILM

ILM [7] không báo cáo AUC/uAUC cho bài toán CTR, nên không thể so sánh số liệu trực tiếp. Đây là lý do chính luận văn đặt ra mục tiêu đánh giá Q-Former dưới quy trình CoLLM: cung cấp cơ sở so sánh công bằng trong cùng điều kiện thực nghiệm.

4.6.2 Ưu điểm và hạn chế của Q-Former

So với mô-đun chiếu MLP của CoLLM, cầu nối Q-Former có cơ chế chọn lọc đặc trưng rõ ràng hơn qua tập truy vấn học được và self-attention. Vì tín hiệu cộng tác chỉ đi qua đường soft token, LLM được giữ nguyên khi suy luận – không có chi phí sinh trọng số theo từng mẫu như hướng sinh

trọng số của CoRA. Đánh đổi là chi phí huấn luyện cầu nối cao hơn lớp MLP đơn giản, cần cân nhắc tùy điều kiện triển khai.

4.7 Hạn chế nghiên cứu

Luận văn thừa nhận các hạn chế thực nghiệm sau:

1. **Một seed:** Số liệu báo cáo từ một lần chạy duy nhất; chưa có khoảng tin cậy, kết quả có thể dao động giữa các lần chạy.
2. **Thiếu ablation attention-MLP:** Chưa có hàng ablation thay cầu nối Q-Former bằng bộ chiếu attention-MLP (không truy vấn học được). Đây là đối chứng quan trọng nhất để cô lập đóng góp của *cấu trúc Q-Former* khỏi phần phi tuyến + attention đơn thuần; hiện được ghi nhận là hướng thực nghiệm còn để ngỏ.
3. **Các ablation thành phần chưa đầy đủ:** Bật/tắt riêng biểu diễn đa token và hàm mất mát bảo toàn thứ tự trên MovieLens-1M đều chưa được chạy dưới cùng backbone Vicuna; kết luận về từng thành phần vì thế còn hạn chế.
4. **Baseline không đồng nhất:** SellaRec dùng backbone Qwen2-Base khác họ với Vicuna; so sánh với SellaRec phản ánh khác biệt cả về cơ chế lẫn backbone LLM. Trên Amazon-Book, số liệu CoLLM/BinLLM/CoRA lấy từ lần chạy lại của CoRA (chọn theo AUC), khác quy trình chọn checkpoint theo uAUC của CoQLLM.
5. **Trên uAUC ở nhóm cold:** uAUC bị chặn trên bởi chất lượng embedding MF cho người dùng/sản phẩm nguội (Mục 4.5.2), không phải bởi cầu nối; cải thiện tiếp theo cần MF teacher mạnh hơn trên nhóm cold.

Chương 5

Kết luận và hướng nghiên cứu

5.1 Tóm tắt đóng góp

Luận văn đặt ra câu hỏi: liệu cầu nối Q-Former – với cơ chế cross-attention có kiểm soát – có thể căn chỉnh tín hiệu cộng tác vào không gian ngữ nghĩa của LLM hiệu quả hơn mô-đun chiếu MLP của CoLLM hay không? Để trả lời, luận văn thiết kế, hiện thực và đánh giá mô hình CoQLLM, đóng góp theo hai hướng đã phát biểu ở Mục 1.4:

Đóng góp 1: Cầu nối Q-Former được thích nghi và tăng cường cho bài toán gợi ý. CoQLLM thay thế mô-đun chiếu MLP pointwise của CoLLM bằng kiến trúc Q-Former, trong đó embedding cộng tác của sản phẩm mục tiêu và của các sản phẩm trong lịch sử thay thế đặc trưng ảnh làm đầu vào cross-attention, tín hiệu người dùng được đưa vào qua điều kiện hóa truy vấn, và toàn bộ được chuyển thành soft token cho LLM. Trên nền đó, luận văn bổ sung hai kỹ thuật huấn luyện – điều kiện hóa truy vấn theo người dùng và mục tiêu bảo toàn thứ tự trong từng người dùng – cùng với biểu diễn đa token như một hệ quả của thiết kế nhiều truy vấn. Kết quả chi tiết được trình bày ở Chương 4.

Đóng góp 2: Đánh giá có hệ thống theo độ đo AUC/uAUC trên hai tập dữ liệu. Luận văn đánh giá cầu nối Q-Former trên bài toán CTR với AUC và uAUC – cùng quy trình với CoLLM – trên MovieLens-

1M và Amazon-Book, cho phép so sánh trực tiếp với CoLLM, BinLLM và CoRA. Phân tích ablation tách biệt đóng góp của từng kỹ thuật, và phân rã warm/cold làm rõ trần uAUC nằm ở chất lượng embedding MF.

5.2 Kết quả chính

Từ kết quả ở Bảng 4.1, Bảng 4.2 và Bảng 4.3, có thể rút ra các kết luận sau:

- **MovieLens-1M – vượt SOTA trên cả hai độ đo.** Cấu hình đề xuất (+ điều kiện hóa) đạt AUC 0,7475 và uAUC 0,6968, vượt BinLLM (0,7425/0,6956) trên cả AUC lẫn uAUC và vượt rõ CoLLM. Đây là điểm đáng chú ý vì nhiều phương pháp cùng hướng chỉ thắng một trong hai độ đo.
- **Amazon-Book – cạnh tranh/vượt baseline trên miền khó.** Với điều kiện hóa truy vấn theo người dùng (Run-1), CoQLLM đạt 0,8147/0,5958, vượt CoLLM-MF và BinLLM (theo lần chạy lại của CoRA) trên cả hai độ đo. Bổ sung hàm mất mát bảo toàn thứ tự (Run-2) nâng uAUC lên 0,6062, tiệm cận CoRA-MF (0,6262).
- **Hai kỹ thuật tác động lên hai độ đo khác nhau.** Điều kiện hóa truy vấn theo người dùng chủ yếu cải thiện AUC (biến thiên giữa các người dùng); hàm mất mát bảo toàn thứ tự chủ yếu cải thiện uAUC (bảo toàn thứ tự trong người dùng). Việc bật theo từng tập dữ liệu là siêu tham số hợp lệ theo miền.
- **Trần uAUC nằm ở MF teacher, không phải cần nổi.** Phân rã warm/cold cho thấy uAUC nhóm warm cao hơn hẳn nhóm cold trên cả hai tập dữ liệu (ví dụ Amazon-Book: 0,6238 vs 0,5258), cho thấy hướng cải thiện tiếp theo nằm ở chất lượng véc-tơ cộng tác cho người dùng/sản phẩm người (cold).

5.3 Hạn chế nghiên cứu

Luận văn nêu rõ các hạn chế sau một cách minh bạch:

1. **Thiếu khoảng tin cậy:** Kết quả từ một seed duy nhất. Biến động thống kê giữa các lần chạy chưa được đo.
2. **Thiếu ablation attention-MLP:** Chưa có hàng ablation thay Q-Former bằng bộ chiếu attention-MLP (không truy vấn học được) – đối chứng quan trọng nhất để cô lập đóng góp của cấu trúc Q-Former. Cùng với các ablation thành phần khác (đa token, tách projector, bảo toàn thứ tự trên MovieLens-1M), đây là phần thực nghiệm còn để ngỏ.
3. **Chi phí tính toán cao hơn CoLLM:** Cầu nối Q-Former làm tăng chi phí huấn luyện so với lớp MLP đơn giản của CoLLM (dù không sinh trọng số theo từng mẫu như CoRA).
4. **Baseline không đồng nhất:** SellaRec dùng backbone LLM khác họ, và trên Amazon-Book số liệu baseline lấy từ lần chạy lại của CoRA (chọn checkpoint theo AUC, khác CoQLLM chọn theo uAUC) – giới hạn khả năng so sánh thuần về cơ chế căn chỉnh.
5. **Trên uAUC ở nhóm cold:** uAUC bị chặn trên bởi chất lượng embedding MF cho người dùng/sản phẩm nguội, không phải bởi cầu nối.

5.4 Hướng nghiên cứu tương lai

Từ các hạn chế và quan sát trên, luận văn đề xuất những hướng nghiên cứu tiếp theo:

Mở rộng thực nghiệm:

- Đánh giá trên Amazon Books và các tập dữ liệu ngoài miền phim để kiểm chứng khả năng tổng quát.
- Chạy nhiều seed và báo cáo $\text{mean} \pm \text{std}$ để đánh giá độ ổn định.

Ablation và phân tích sâu hơn:

- Bổ sung hàng ablation attention-MLP (bộ chiếu có self-attention nhưng không có truy vấn học được) để cô lập đóng góp của cấu trúc Q-Former khỏi phần phi tuyến + attention đơn thuần.
- Phân tích attention map của Q-Former để hiểu truy vấn nào học cách trích xuất thông tin gì từ tín hiệu cộng tác.

Cải thiện uAUC:

- Tiền huấn luyện MF trên dữ liệu dày đặc hơn (nhiều tháng hơn), đặc biệt cho nhóm người dùng/sản phẩm ngoại – điều mà phân rã warm/cold chỉ ra là trần thực sự của uAUC.
- Mở rộng mục tiêu bảo toàn thứ tự (đã hiệu quả trên Amazon-Book) sang các miền khác và khảo sát trọng số λ tối ưu theo từng tập.

Mở rộng kiến trúc:

- Bổ sung hàng ablation attention-MLP và các ablation thành phần còn để ngỏ dưới cùng backbone Vicuna để cô lập đầy đủ đóng góp của cấu trúc Q-Former.
- Khảo sát hướng sinh trọng số kiểu CoRA như một đường *bổ sung* cho soft token (chưa hiện thực trong luận văn này) để so sánh trực tiếp hai cơ chế đưa tín hiệu cộng tác vào LLM.
- Khảo sát các backbone LLM khác (Llama-3, Mistral) để kiểm chứng tính tổng quát của cầu nối Q-Former.

Tài liệu tham khảo

- [1] S. Zhang, L. Yao, A. Sun, and Y. Tay, “Deep learning based recommender system: A survey and new perspectives,” *ACM Computing Surveys*, vol. 52, no. 1, pp. 1–38, 2019. DOI: 10.1145/3285029
- [2] Y. Koren, R. Bell, and C. Volinsky, “Matrix factorization techniques for recommender systems,” *Computer*, vol. 42, no. 8, pp. 30–37, 2009. DOI: 10.1109/MC.2009.263
- [3] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, “LightGCN: Simplifying and powering graph convolution network for recommendation,” in *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2020, pp. 639–648. DOI: 10.1145/3397271.3401063
- [4] L. Wu et al., “A survey on large language models for recommendation,” *arXiv preprint arXiv:2305.19860*, 2023.
- [5] Y. Zhang, F. Feng, J. Zhang, K. Lv, and X. He, “CoLLM: Integrating collaborative embeddings into large language models for recommendation,” *arXiv preprint arXiv:2310.19488*, 2023.
- [6] J. Li, D. Li, S. Savarese, and S. Hoi, “BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models,” in *Proceedings of the 40th International Conference on Machine Learning*, 2023, pp. 19 730–19 742.
- [7] L. Yang et al., “Item-language model for conversational recommendation,” *arXiv preprint arXiv:2406.02844*, 2024.

- [8] W.-L. Chiang et al., “Vicuna: An open-source chatbot impressing GPT-4 with 90%* ChatGPT quality,” <https://lmsys.org/blog/2023-03-30-vicuna/>, 2023.
- [9] E. J. Hu et al., “LoRA: Low-rank adaptation of large language models,” in *International Conference on Learning Representations*, 2022.
- [10] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, “BPR: Bayesian personalized ranking from implicit feedback,” in *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence*, 2009, pp. 452–461.
- [11] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, and T.-S. Chua, “Neural collaborative filtering,” in *Proceedings of the 26th International Conference on World Wide Web*, 2017, pp. 173–182. DOI: 10.1145/3038912.3052569
- [12] S. Geng, S. Liu, Z. Fu, Y. Ge, and Y. Zhang, “Recommendation as language processing (RLP): A unified pretrain, personalized prompt & predict paradigm (P5),” in *Proceedings of the 16th ACM Conference on Recommender Systems*, 2022, pp. 299–315. DOI: 10.1145/3523227.3546767
- [13] K. Bao et al., “BIGRec: A generalizable and controllable large language model framework for recommendation,” *arXiv preprint arXiv:2308.12242*, 2023.
- [14] Z. Wang et al., “Enhancing LLM-based recommendation through semantic-aligned collaborative knowledge,” *arXiv preprint arXiv:2504.10107*, 2025.
- [15] A. Yang et al., “Qwen2 technical report,” *arXiv preprint arXiv:2407.10671*, 2024.
- [16] Y. Zhang, K. Bao, M. Yan, W. Wang, F. Feng, and X. He, “Text-like encoding of collaborative information in large language models for recommendation,” in *Proceedings of the 62nd Annual Meet-*

ing of the Association for Computational Linguistics (ACL 2024), arXiv:2406.03210; model referred to in thesis as BinLLM, 2024.

- [17] J. Zhang, K. Bao, Y. Zhang, W. Wang, F. Feng, and X. He, “CoRA: Collaborative information perception by large language model’s weights for recommendation,” *arXiv preprint arXiv:2408.10645*, 2024.
- [18] F. M. Harper and J. A. Konstan, “The MovieLens datasets: History and context,” *ACM Transactions on Interactive Intelligent Systems*, vol. 5, no. 4, pp. 1–19, 2015. DOI: 10.1145/2827872